

# Estadística Aplicada III

## Distribución normal multivariada

### Distribuciones muestrales

Jorge de la Vega Góngora

Departamento de Estadística,  
Instituto Tecnológico Autónomo de México

Semana 4



**ITAM**

# Resumen

- Hemos visto que los estimadores máximo verosímiles para  $\mu$  y  $\Sigma$  de una muestra  $\mathbf{x}_1, \dots, \mathbf{x}_n \sim \mathcal{N}_p(\mu, \Sigma)$  están dados por:
  - $\hat{\mu} = \bar{\mathbf{x}} \sim \mathcal{N}_p(\mu, \frac{1}{n}\Sigma)$
  - $\hat{\Sigma} = \mathbf{S}_n = \left(\frac{n-1}{n}\right) \mathbf{S}$ .
  - La distribución de la forma cuadrática  $(\mathbf{x} - \mu)' \Sigma^{-1} (\mathbf{x} - \mu)$  es  $\chi_{(p)}^2$ .
- Todavía tenemos que revisar las siguientes ideas:
  - ¿Cuál es la relación entre  $\bar{\mathbf{x}}$  y  $\mathbf{S}$ ?
  - ¿Cómo se distribuye  $\frac{n-1}{n} \mathbf{S}$ ?
  - ¿Cómo se distribuye  $(\mathbf{x} - \bar{\mathbf{x}})' \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}})$ , la forma cuadrática de la distancia estadística sustituyendo los parámetros por sus estimadores?

- En el caso univariado, cabe recordar que se tienen las siguientes distribuciones muestrales:
  - $\bar{X} \sim \mathcal{N}(\mu, \sigma^2)$
  - $(n-1)s^2 = \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi_{(n-1)}^2$
  - $\bar{X}$  y  $s^2$  son independientes.
- Podemos notar que podemos reescribir, si  $Z_i \sim \mathcal{N}(0, 1)$ ,  $i = 1, \dots, n-1$  independientes, entonces  $(n-1)s^2 \stackrel{d}{=} (\sigma Z_1)^2 + \dots + (\sigma Z_{n-1})^2 \sim \chi_{n-1}^2$ . Esta forma es la que nos permitirá extender la definición al caso multivariado.

## Distribución Wishart

- La distribución muestral de la matriz de varianzas y covarianzas de una normal multivariada se llama la *distribución de Wishart* y se define como la distribución de la suma de productos independientes de vectores normales:

$$\mathcal{W}_m(\cdot|\Sigma) \stackrel{d}{=} \sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i'$$

donde  $\mathbf{z}_i \sim \mathcal{N}_p(\mathbf{0}, \Sigma)$  y  $\mathbf{z}_i \perp\!\!\!\perp \mathbf{z}_j$ .

- La densidad Wishart con  $m$  grados de libertad para una matriz  $\mathbf{A}_{p \times p}$  definida positiva, cuando  $n > p$ , está dada por:

$$w_m(\mathbf{A}|\Sigma) = \frac{|\mathbf{A}|^{\frac{m-p-1}{2}} e^{-\text{tr}[\mathbf{A}\Sigma^{-1}]/2}}{2^{pm/2} \pi^{p(p-1)/4} |\Sigma|^{m/2} \prod_{i=1}^p \Gamma\left(\frac{1}{2}(m+1-i)\right)}$$

Entonces  $n\hat{\Sigma} = (n-1)\mathbf{S} \sim \mathcal{W}_{n-1}((n-1)\mathbf{S}|\Sigma)$ . Por último, se puede probar que  $\bar{\mathbf{x}}$  y **S** son independientes.

# Propiedades de la distribución Wishart

- La distribución Wishart es la generalización multivariada de la distribución  $\chi^2$ .
- Las siguientes propiedades de la distribución Wishart serán utilizadas en algunos casos más adelante:

❶ Si  $\mathbf{S}_1 \sim \mathcal{W}_n(\mathbf{S}_1|\Sigma)$  y  $\mathbf{S}_2 \sim \mathcal{W}_m(\mathbf{S}_2|\Sigma)$  independientes, entonces

$$\mathbf{S} = \mathbf{S}_1 + \mathbf{S}_2 \sim \mathcal{W}_{n+m}(\mathbf{S}|\Sigma).$$

❷ Si  $\mathbf{S} \sim \mathcal{W}_n(\mathbf{S}|\Sigma)$  y  $\mathbf{C}_{l \times p} \neq \mathbf{0}$  entonces

$$\mathbf{B} = \mathbf{CSC}' \sim \mathcal{W}_n(\mathbf{B}|\mathbf{C}\Sigma\mathbf{C}').$$

❸ La densidad Wishart existe cuando  $n > p$ .

# Teorema del límite central multivariado

## Teorema del límite central

Sea  $\mathbf{X}_1, \dots, \mathbf{X}_n$  una muestra aleatoria de una población con media  $\boldsymbol{\mu}$  y covarianza finita no singular  $\boldsymbol{\Sigma}$ . Entonces

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \dot{\sim} \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$$

para tamaños de muestra  $n$  grandes y  $n \gg p$ .

- Como consecuencia del teorema del límite central, se tiene que  $n(\bar{\mathbf{X}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \dot{\sim} \chi^2_{(p)}$  para  $n - p$  grande.
- Notar que la aproximación es para cualquier distribución, no necesariamente normal.

# Distribución $T^2$ de Hotelling I

- Cabe recordar que en el caso univariado, si  $X \sim \mathcal{N}(\mu_0, 1)$  independiente de  $V \sim \chi^2_{(p)}$ , entonces

$$t = \frac{X - \mu_0}{\sqrt{(V/n)}} \sim t_{(n)}$$

y adicionalmente, sabemos que  $t^2_{(n)} = n(X - \mu_o)(s^2)^{-1}(X - \mu_o) \sim F_{1,p}$ , donde  $F_{u,v}$  es la distribución F de Fisher, con  $u$  y  $v$  grados de libertad.

- La generalización de la distribución  $t$  al caso multivariado, corresponde a la distribución de una forma cuadrática.



# Distribución $T^2$ de Hotelling II

## Distribución $T^2$ de Hotelling

Para una muestra aleatoria  $\mathbf{x}_1, \dots, \mathbf{x}_n \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , y si  $\boldsymbol{\mu}_0$  es un vector fijo, la estadística

$$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) \sim \frac{(n-1)p}{n-p} F_{p, n-p}.$$

Esta estadística es llamada  *$T^2$  de Hotelling*. Esta estadística combina una normal multivariada con una matriz Wishart, y es análoga a la distribución  $t$  univariada elevada al cuadrado, que coincide con una distribución  $F$ .

- Para la estadística  $T^2$  de Hotelling, una de sus principales características es que es invariante bajo transformaciones afines  $\mathbf{y} = \mathbf{C}\mathbf{x} + \mathbf{d}$ , donde  $\mathbf{C}$  no sea singular. Esto es fácil de demostrar considerando las propiedades de la media y varianza de  $\mathbf{y}$  a partir de la de  $\mathbf{x}$ .

- 1 Con la matriz de datos  $\mathbf{X} = \begin{bmatrix} 2 & 12 \\ 8 & 9 \\ 6 & 9 \\ 8 & 10 \end{bmatrix}$ , calculen  $T^2$  para la prueba  $H_0 : \boldsymbol{\mu}' = (7, 11)$ , suponiendo que los datos son muestra de una distribución binormal.
- 2 ¿Cuál es la distribución de  $T^2$ ?
- 3 ¿Cómo se distribuye  $3\mathbf{S}$ ?

**Solución.**

# Ejemplos II

```
X <- matrix(c(2,8,6,8,12,9,9,10),nrow=4)
n <- dim(X)[1]
mu <- c(7,11)
(S <- var(X))

      [,1]      [,2]
[1,]  8.000000 -3.333333
[2,] -3.333333  2.000000

(Sinv <- solve(S))

      [,1]      [,2]
[1,] 0.4090909 0.6818182
[2,] 0.6818182 1.6363636

(xbar <- colMeans(X))

[1]  6 10

(T2 <- as.numeric(n*(t(xbar-mu) %*% Sinv %*% (xbar-mu))))

[1] 13.63636
```

La distribución de  $T^2 \sim \frac{2(4-1)}{4-2} F_{2,4-2} = 3F_{2,2}$ . La distribución de la matriz  $3\mathbf{S}$  es Wishart con 3 grados de libertad.



- 4 Verifiquen que pasa con  $T^2$  si cada caso de la matriz  $\mathbf{X}$  se sustituye por  $\mathbf{C}\mathbf{x}_i + \mathbf{d}$ , donde  $\mathbf{C} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$  y  $\mathbf{d} = (1, 1)'$ .

## ***Solución.***

```
C <- matrix(c(1,1,-1,1),nrow=2)
Y <- X %*% t(C) + c(1,1)
ybar <- colMeans(Y)
S2 <- var(Y)
muy <- C%*%mu + c(1,1)
T3 <- as.numeric(n*(t(ybar-muy) %*% solve(S2) %*% (ybar-muy)))
T3

[1] 13.63636
```

Vimos que la distribución no cambia bajo transformaciones afines, por las propiedades de las medias y las varianzas.



# Requerimientos de optimización matricial

- Durante el curso en diversas partes utilizaremos los siguientes resultados de optimización de cocientes de formas cuadráticas, que parten en todos los casos de la desigualdad de Cauchy-Schwarz. Revisaremos los resultados para tenerlos presentes.

## Teorema (Desigualdad de Cauchy-Schwarz)

Sean  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ . Entonces

$$(\mathbf{x}'\mathbf{y})^2 \leq (\mathbf{x}'\mathbf{x})(\mathbf{y}'\mathbf{y})$$

y la igualdad se cumple si y sólo si  $\mathbf{x} = c\mathbf{y}$  para alguna  $c \in \mathbb{R}$

# Un recordatorio rápido II

- El primer paso es extender esta desigualdad para incorporar una matriz definida positiva.

## Teorema (Desigualdad de Cauchy-Schwarz extendida)

Sean  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$  y  $\mathbf{B}_{p \times p} > 0$  (definida positiva). Entonces:

$$(\mathbf{x}'\mathbf{y})^2 \leq (\mathbf{x}'\mathbf{B}\mathbf{x})(\mathbf{y}'\mathbf{B}^{-1}\mathbf{y})$$

y la igualdad se da si y sólo si  $\mathbf{x} = c\mathbf{B}^{-1}\mathbf{y}$  para alguna  $c \in \mathbb{R}$ .

### ***Demostración.***

Básicamente tenemos que escribir  $\mathbf{B} = \mathbf{B}^{1/2}\mathbf{B}^{1/2}$  usando la descomposición espectral. Entonces

$$\mathbf{x}'\mathbf{y} = \mathbf{x}'\mathbf{I}\mathbf{y} = \mathbf{x}'\mathbf{B}^{1/2}\mathbf{B}^{-1/2}\mathbf{y} = (\mathbf{B}^{1/2}\mathbf{x})'(\mathbf{B}^{-1/2}\mathbf{y})$$

# Un recordatorio rápido III

y el resultado sigue por la desigualdad de Cauchy-Schwarz.



- El siguiente lema es el primer resultado sobre optimización del cociente de formas cuadráticas.

## Lema

Sea  $\mathbf{B}_{p \times p} > 0$  y  $\mathbf{a} \in \mathbb{R}^p$ . Entonces para todo vector  $\mathbf{x} \neq \mathbf{0}$  en  $\mathbb{R}^p$

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{(\mathbf{x}'\mathbf{a})^2}{\mathbf{x}'\mathbf{B}\mathbf{x}} = \mathbf{a}'\mathbf{B}^{-1}\mathbf{a}$$

donde el máximo se alcanza cuando  $\mathbf{x} = c\mathbf{B}^{-1}\mathbf{a}$  para alguna  $c \neq 0$ .

***Demostración.***



# Un recordatorio rápido IV

Por el teorema extendido de Cauchy-Schwarz  $(\mathbf{x}'\mathbf{a})^2 \leq (\mathbf{x}'\mathbf{B}\mathbf{x})(\mathbf{a}'\mathbf{B}^{-1}\mathbf{a})$ . Además como  $\mathbf{x} \neq \mathbf{0}$  y  $\mathbf{B} > \mathbf{0}$ ,  $\mathbf{x}'\mathbf{B}\mathbf{x} > 0$ . Entonces:

$$\frac{(\mathbf{x}'\mathbf{a})^2}{\mathbf{x}'\mathbf{B}\mathbf{x}} \leq \mathbf{a}'\mathbf{B}^{-1}\mathbf{a}$$

Como la igualdad se alcanza con  $\mathbf{x} = \mathbf{B}^{-1}\mathbf{a}$ , está claro que:

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{(\mathbf{x}'\mathbf{a})^2}{\mathbf{x}'\mathbf{B}\mathbf{x}} = \mathbf{a}'\mathbf{B}^{-1}\mathbf{a}$$

□

# Un recordatorio rápido V

- Por ultimo, el siguiente teorema relaciona los óptimos con los eigenvalores.

## Teorema (Maximización de formas cuadráticas para puntos en la esfera unitaria)

Sea  $\mathbf{B}_{p \times p} > \mathbf{0}$  con eigenvalores  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$  y correspondientes eigenvectores normalizados  $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p\}$ . Entonces:

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}' \mathbf{B} \mathbf{x}}{\mathbf{x}' \mathbf{x}} = \lambda_1 \quad \text{que se alcanza cuando } \mathbf{x} = \mathbf{e}_1$$

$$\min_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}' \mathbf{B} \mathbf{x}}{\mathbf{x}' \mathbf{x}} = \lambda_p \quad \text{que se alcanza cuando } \mathbf{x} = \mathbf{e}_p$$

$$\max_{\mathbf{x} \perp \mathbf{e}_1, \dots, \mathbf{e}_k} \frac{\mathbf{x}' \mathbf{B} \mathbf{x}}{\mathbf{x}' \mathbf{x}} = \lambda_{k+1} \quad \text{que se alcanza cuando } \mathbf{x} = \mathbf{e}_{k+1}, \quad k = 1, 2, \dots, p-1$$

# Un recordatorio rápido VI

## ***Demostración.***

Supongamos que  $\mathbf{B} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}'$  es la descomposición espectral de tal manera que  $\mathbf{B}^{1/2} = \mathbf{P}\mathbf{\Lambda}^{1/2}\mathbf{P}'$ , donde la matriz  $\mathbf{P}$  cumple con la condición  $\mathbf{P}'\mathbf{P} = \mathbf{P}\mathbf{P}' = \mathbf{I}$ . Sea  $\mathbf{y} = \mathbf{P}'\mathbf{x}$ . Entonces, si  $\mathbf{x} \neq \mathbf{0}$ ,  $\mathbf{y} \neq \mathbf{0}$  y

$$\begin{aligned}\frac{\mathbf{x}'\mathbf{B}\mathbf{x}}{\mathbf{x}'\mathbf{x}} &= \frac{\mathbf{x}'\mathbf{B}^{1/2}\mathbf{B}^{1/2}\mathbf{x}}{\mathbf{x}'\mathbf{P}\mathbf{P}'\mathbf{x}} = \frac{\mathbf{x}'\mathbf{P}\mathbf{\Lambda}^{1/2}\mathbf{P}'\mathbf{P}\mathbf{\Lambda}^{1/2}\mathbf{P}'\mathbf{x}}{\mathbf{y}'\mathbf{y}} \\ &= \frac{\mathbf{y}'\mathbf{\Lambda}\mathbf{y}}{\mathbf{y}'\mathbf{y}} \\ &= \frac{\sum_{i=1}^p \lambda_i y_i^2}{\sum_{i=1}^p y_i^2} \\ &\leq \lambda_1 \frac{\sum_{i=1}^p y_i^2}{\sum_{i=1}^p y_i^2} = \lambda_1\end{aligned}$$

Si se toma  $\mathbf{x} = \mathbf{e}_1$  entonces  $\mathbf{y} = \mathbf{P}'\mathbf{e}_1 = \mathbf{e}_1$ , entonces  $\frac{\mathbf{e}_1'\mathbf{B}\mathbf{e}_1}{\mathbf{e}_1'\mathbf{e}_1} = \mathbf{e}_1'\mathbf{B}\mathbf{e}_1 = \lambda_1$ .

# Un recordatorio rápido VII

Por otra parte,  $\mathbf{y} = \mathbf{P}'\mathbf{x} \Rightarrow \mathbf{P}\mathbf{y} = \mathbf{x} = \sum_{i=1}^p y_i \mathbf{e}_i$ . Si  $\mathbf{x} \perp \mathbf{e}_1, \dots, \mathbf{e}_k$  entonces

$$0 = \mathbf{e}_i' \mathbf{x} = y_1 \mathbf{e}_1' \mathbf{e}_1 + y_2 \mathbf{e}_2' \mathbf{e}_2 + \dots + y_p \mathbf{e}_p' \mathbf{e}_p = y_i, \quad i \leq k$$

Por lo tanto el cociente se puede escribir como:

$$\frac{\mathbf{x}'\mathbf{B}\mathbf{x}}{\mathbf{x}'\mathbf{x}} = \frac{\sum_{i=k+1}^p \lambda_i y_i^2}{\sum_{i=k+1}^p y_i^2}$$

Si tomamos  $y_{k+1} = 1$  y el resto de las  $y_{k+i} = 0$  para  $i = 2, \dots, p$ , se obtiene el máximo establecido.

□

## **Ejemplo. []**

Sea  $\mathbf{B} = \begin{pmatrix} 2.2 & 0.4 \\ 0.4 & 2.8 \end{pmatrix}$ . consideremos como función de  $\mathbf{x}$  la forma cuadrática  $g(\mathbf{x}) = \frac{\mathbf{x}'\mathbf{B}\mathbf{x}}{\mathbf{x}'\mathbf{x}}$ .

# Un recordatorio rápido VIII

Los eigenvalores de **B** son  $\lambda_1 = 3$  y  $\lambda_2 = 2$  y la matriz **P** =  $\begin{pmatrix} 0.4472136 & -0.8944272 \\ 0.8944272 & 0.4472136 \end{pmatrix}$  es la matriz de eigenvectores. Las direcciones hacia donde se maximiza y minimiza respectivamente la función  $g(\mathbf{x})$  son precisamente las columnas de **P**, que se muestran en la gráfica con las flechas. Adicionalmente se generan una muestra de puntos para calcular el valor de la función  $g$  y ver que precisamente en la dirección de esos dos vectores es donde se tiene el valor más alto y el más bajo respectivamente.

# Un recordatorio rápido IX

```
options(scipen=5) #control de expansión en notación científica
set.seed(100)
B <- matrix(c(2.2,.4,.4,2.8),nrow=2) #matriz ejemplo

#Define la función cociente forma cuadrática
g <- function(x,Q){ as.numeric((t(x) %*% Q %*% x)/sum(x*x))}

#genera algunas direcciones al azr en el cuadro [-2,2]^2
vectores <- cbind(runif(100,-2,2),runif(100,-2,2))
#calcula la función cuadrática en esas direcciones
z <- apply(vectores, 1, g, Q = B)
z

[1] 2.865464 2.605354 2.702268 2.481084 2.405223 2.725723 2.985216 2.261115
[9] 2.719030 2.121670 2.988370 2.825763 2.999635 2.991407 2.997557 2.471272
[17] 2.221621 2.268857 2.999396 2.997854 2.488158 2.000051 2.024597 2.502406
[25] 2.998946 2.979134 2.998698 2.947164 2.914689 2.997919 2.834432 2.842367
[33] 2.265531 2.195287 2.566529 2.173319 2.273766 2.546125 2.143509 2.015677
[41] 2.106951 2.139769 2.185648 2.955779 2.554457 2.768516 2.991348 2.157182
[49] 2.993137 2.988717 2.176551 2.223113 2.972192 2.982185 2.941364 2.184734
[57] 2.074136 2.120140 2.620404 2.018893 2.701188 2.612524 2.166557 2.344150
[65] 2.894450 2.995829 2.868977 2.566814 2.107218 2.998822 2.781370 2.625233
[73] 2.943850 2.770820 2.998349 2.217282 2.961285 2.682076 2.111565 2.043335
[81] 2.926591 2.998736 2.902600 2.525851 2.761411 2.350119 2.275301 2.988704
[89] 2.904123 2.980375 2.949500 2.392441 2.999654 2.704568 2.554010 2.998603
[97] 2.762132 2.040846 2.828235 2.917087

#Ahora calcula los valores propios, grafica las direcciones de los vectores propios y muestra las direcciones simuladas
```

# Un recordatorio rápido X

```
lambdas <- eigen(B)$values
P <- eigen(B)$vectors
par(pty = "s") #gráfica cuadrada
plot(c(-2,2), c(-2,2), type = "n", xlim = c(-2,2), ylim = c(-2,2), xlab = "", ylab = "",
     main = "gráfica de la función g(x) y su valor") #gráfica vacía
abline(h=0)
abline(v=0)
arrows(0,0,P[1,1],P[2,1], length = 0.1, lwd = 2)
arrows(0,0,P[1,2],P[2,2], length = 0.1, lwd = 2)
arrows(0,0,vectores[,1],vectores[,2], length=0.1, pch = 16, cex = 0.5, lty=3, col = "gray2")
text(vectores, labels = round(z,3), adj=c(0,-0.2), cex = 0.7, col = "red")
```

# Un recordatorio rápido XI

gráfica de la función  $g(x)$  y su valor

